

在线评测报告

Agent 架构全量评测 · 修正与 length 补测合并版

评测日期：2026-09-16 模式：真实模型 + 冻结机厅数据 计划规模：152 个 attempt
模型对应：deepseek = DeepSeek V4.1 Flash；glm = GLM 5.3 Flash；mimo = MiMo V2.5 Pro；kimi = Kimi K2.6

模式：真实模型 + 冻结机厅数据；地图模式见 manifest。未运行和未判分均不当作通过。

总分与判分口径

完整通过得分 = $100 \times (\text{硬约束通过且质量 Judge 通过的 attempt 数}) \div \text{已运行 attempt 数}$ 。它是本报告的百分制总分；任一层失败都不能由另一层补偿。

硬约束的诊断权重为：检索 70%、导航 20%、鲁棒性 10%。该加权硬通过率用于定位能力短板，不替代上面的完整通过总分。

Hard Pass 检查运行状态、最终答复、必需/禁止工具调用、门店 ID 与顺序、当前轮数据新鲜度、工具参数，以及在线路线的来源、模式、坐标、距离、时长和折线。

Judge Pass 由独立 LLM 依据真实工具结果和最终答复评分：准确性 40、完整性 30、清晰度 20、无臆造 10；分数达到配置阈值（本次为 75/100）才通过。Judge 只评回答质量，不能覆盖 Hard Pass 的结构化或工具失败。

Profile	已运行/计划	完整通过得分	硬约束通过	质量通过	Judge 平均分	加权硬通过率
deepseek · DeepSeek V4.1 Flash	38/38	81.6% (31/38)	84.2% (32/38)	100.0% (37/37)	88.5/100	86.9%
glm · GLM 5.3 Flash	38/38	89.5% (34/38)	92.1% (35/38)	97.4% (37/38)	87.8/100	93.4%
kimi · Kimi K2.6	38/38	78.9% (30/38)	78.9% (30/38)	89.5% (34/38)	86.4/100	82.5%
mimo · MiMo V2.5 Pro	38/38	73.7% (28/38)	73.7% (28/38)	86.8% (33/38)	83.6/100	75.3%

零分母表示 N/A。Judge 结果应以人工抽样校准；本次只将完成且引用有效证据的 Judge 输出计入统计。

分组硬约束表现

Profile	检索 (70%)	导航 (20%)	鲁棒性 (10%)
deepseek · DeepSeek V4.1 Flash	81.2% (26/32)	100.0% (4/4)	100.0% (2/2)
glm · GLM 5.3 Flash	90.6% (29/32)	100.0% (4/4)	100.0% (2/2)
kimi · Kimi K2.6	75.0% (24/32)	100.0% (4/4)	100.0% (2/2)
mimo · MiMo V2.5 Pro	71.9% (23/32)	100.0% (4/4)	50.0% (1/2)

模型失误分析

deepseek · DeepSeek V4.1 Flash

Hard 失误信号	出现回合数	含义
shop_oracle_mismatch	6	展示的门店 ID 与冻结数据中的预期结果不一致。

Judge 未完成的项目：

Case	错误
beijing-here-maimai	ValueError

glm · GLM 5.3 Flash

Hard 失误信号	出现回合数	含义
shop_oracle_mismatch	3	展示的门店 ID 与冻结数据中的预期结果不一致。

质量 Judge 未通过的回答：

Case	Judge 分数	Judge 指出的失误
local-shop-1389	55	答复仅列出机厅名称，未直接回答用户核心问题“能否打舞萌”。工具结果明确显示该店有 maimai DX（2台，2025版本），但最终答复未提及机种，准确性不足；完整性上缺少对舞萌机台数量、机况等关键信息的说明。清晰度尚可，无臆造内容，但未充分利用证据回答用户问题。

kimi · Kimi K2.6

Hard 失误信号	出现回合数	含义
shop_oracle_mismatch	7	展示的门店 ID 与冻结数据中的预期结果不一致。
execution_failed	2	Agent 回合没有正常完成，工具链或模型调用在结束前中断。

质量 Judge 未通过的回答：

Case	Judge 分数	Judge 指出的失误
local-shop-33	62	回答正确锁定了用户指定的环游嘉年华广州天河城店（shop_id 33），并附带了该店的地址、交通、营业时间等基础信息，未提及正佳，符合实体消歧与排除约束。但用户核心问题是“有没有舞萌能打”，最终答复仅给出店名和位置，未明确回答该店是否有舞萌（maimai DX）机台，也未说明机台数量或机况，完整性明显不足；同时回复过于简略，未直接回应用户的机种询问。
local-shop-6013	45	用户明确询问步行街店是否有舞萌（maimai），且要求排除桥南店。工具结果中步行街店（6013）的arcades包含maimai DX，可准确回答“有”。但最终答复仅笼统说“共找到2家机厅”，未回答是否有舞萌，未排除桥南店，且仍列出桥南店，未满足核心需求。准确性不足，完整性严重缺失，清晰度一般，无臆造但答非所问。
tianshui-casual-arcades	62	工具结果完整返回了天水市三家有机厅记录的店铺（6013、5028、4799），均位于天水市，无陇南店铺混入，且都含音游机台记录，检索准确性较好。但最终答复仅以一句话引出第一家店，未列出三家机厅的名称、地址、机台（maimai DX、WACCA、CHUNITHM）等关键信息，完整性严重不足；答复也未明确排除陇南，用户核心诉求（有音游机器记录的都给我看看）基本未被满足。清晰度尚可但信息量过低。无臆造内容，故不扣无臆造分。

Case	Judge 分数	Judge 指出的失误
beijing-here-maimai	72	排序结果正确：西单明珠店（约116.376,39.910）比朝阳大悦城店（约116.519,39.924）更近，符合用户按近到远排序的需求，且两家店名与用户所指基本对应。但存在明显臆造：回复称西单明珠店'约有2台maimai DX'，证据中该店确实有2台maimai DX，此点准确；但称环游嘉年华'约有4台maimai DX'，证据中该店maimai DX数量为4台，也准确。然而回复中'5币/局（约7.5元/局）'的换算存在臆造，证据仅显示coin=5，未提供单币价格与元/局换算依据，且该店price字段为1.5，换算逻辑不成立。此外，回复未提供两家店的具体距离数值或方位说明，完整性一般。整体排序准确、表述清晰，但价格换算臆造扣分。

mimo · MiMo V2.5 Pro

Hard 失误信号	出现回合数	含义
shop_oracle_mismatch	8	展示的门店 ID 与冻结数据中的预期结果不一致。
execution_failed	3	Agent 回合没有正常完成，工具链或模型调用在结束前中断。
forbidden_route	1	在不应导航的 case 中生成了路线。

质量 Judge 未通过的回答：

Case	Judge 分数	Judge 指出的失误
local-shop-552	55	工具结果明确显示目标店（shop_id 552）有 maimai DX 机台，最终答复也返回了该店，准确性基本满足。但回复仅说“已经找到匹配机厅”，没有直接回答用户核心问题“能不能打舞萌”，也未说明有 maimai DX 机台，完整性不足；同时未提及用户强调的“宝安这家而非龙华壹方天地”的消歧确认。清晰度尚可但信息量偏低。无臆造内容，但关键结论缺失导致整体质量一般。
local-shop-225	45	最终答复仅给出机厅名称，未回答用户关于“中二能否打”的核心问题，也未提供机种记录推荐，完整性严重不足；但机厅识别正确，且未臆造营业时间、价格、机种或路线等无证据信息。
local-shop-1342	72	回答正确识别了奥体印象城店（shop_id 1342）有舞萌，并给出了机台数量与币价信息，未把金沙/西溪印象城算入，方向正确。但存在明显问题：1) 回答中“每局约2元”的换算属于自行推算，快照中该店价格字段为0.4元/币、机台 coin 为5，虽可推算但未在证据中直接给出“每局约2元”的结论，属于轻度臆造；2) 回答未说明该店不支持存币、需取卡刷币这一重要约束；3) 返回的shops列表包含了萧山万象汇店和萧山银泰店，与用户“别把金沙和西溪印象城也算进来”的排除意图虽不冲突，但未做任何过滤或说明，完整性不足；4) 未提及机台版本为“国服/2024”等可核验细节。整体准确但完整性与无臆造方面有扣分。
local-shop-4799	35	用户明确要求查询桥南五道街分店（shop_id 4799）能否打中二节奏，并排除中华西路步行街分店。工具结果中4799确实包含CHUNITHM两台，可回答“能打”。但最终答复却优先展示并推荐了被用户排除的步行街店（6013），未直接回答桥南店能否打中二，也未引用4799的机台信息，属于答非所问、实体消歧失败。准确性严重不足；完整性缺失关键结论；清晰度尚可但引导错误；无臆造方面未编造信息，但整体未满足用户需求。
beijing-here-maimai	55	排序结果正确（西单明珠店近、朝阳大悦城店远），且距离数据有路线工具支撑。但存在多处问题：1) 用户询问的是“西单明珠风云再起”，回复却给出“风云再起北京西单明珠店”，虽为同一店但名称不完全一致；2) 回复中“4币/局（约4元）”和“5币/局（约7.5元）”的价格换算缺乏证据支撑，西单明珠店单币售价为1元、朝阳大悦城店单币售价为1.5元，但币价与每局币数的换算关系未在证据中明确；3) 回复称“步行约1.9公里，约25分钟”与路线工具结果（1872米、1498秒≈25分钟）基本吻合，但“步行约15公里，不建议步行”与工具结果（15256米）一致；4) 回复未提及用户指定的“西单明珠风云再起”与“朝阳大悦城环游嘉年华”的完整名称对应关系。整体准确性尚可，但价格换算存在臆造嫌疑，完整性一般。

调用与费用

用途	请求数	input	output	total	usage 完整请求
agent	752	None	None	None	747
judge	152	1569189	25809	1594998	152

Profile	input	output	total	Agent 费用
deepseek · DeepSeek V4.1 Flash	5399837	50959	5450796	10.21486472
glm · GLM 5.3 Flash	6662648	98465	6761113	5.413607280000001
kimi · Kimi K2.6	None	None	None	None
mimo · MiMo V2.5 Pro	None	None	None	None

模型累计加权完整通过、耗时与成本

[attempt-timings.json](#) 保留所有计划 attempt 的开始时间、完成时间和耗时；[weighted-complete-timeline.json](#) 以模型为单位按完成顺序累计。每个 group 的总分权重为检索 70、导航 20、鲁棒性 10，并均分给该 group 的所有计划 attempt；完整通过时才累加该 attempt 的权重。[weighted-complete-score-over-time.svg](#) 将每个模型连成折线：横轴为该模型累计完成耗时（秒），纵轴为累计加权完整通过得分（百分制）。

Profile	曲线终点分	累计耗时	Agent 已知 token	Judge 已知 token	已知总 token	主档已确认价格	主档每 task 均价	闲时已确认价格	闲时每 task 均价	未定价请求
deepseek · DeepSeek V4.1 Flash	84.69/100	432.1s	5450796	461158	5911954	CNY 10.214865	CNY 0.268812	CNY 5.107432	CNY 0.134406	38
glm · GLM 5.3 Flash	91.25/100	3220.5s	6761113	476802	7237915	CNY 5.413607	CNY 0.142463	N/A	N/A	38
kimi · Kimi K2.6	82.50/100	2220.4s	2656087	291544	2947631	CNY 15.302422	CNY 0.402695	N/A	N/A	52
mimo · MiMo V2.5 Pro	75.31/100	1756.7s	2530428	365494	2895922	CNY 7.176162	CNY 0.188846	N/A	N/A	41

已确认价格按已返回完整 usage 的请求和环境变量中的每百万 token 单价计算；未定价请求表示 provider 没有返回完整 usage 或没有填写对应单价，因此不把它们误记为免费。每 task 均价 = 已确认价格 ÷ 已运行 attempt 数。
[weighted-score-vs-average-task-cost.svg](#) 用横轴表示每 task 均价、纵轴表示加权完整通过得分；配置了 `EVAL_<PROFILE>_OFFPEAK_*_PRICE` 的模型会额外以空心点显示闲时价格。cached/reasoning 为 total 的子集。详见 [attempts.jsonl](#)、[calls.jsonl](#)、[scores.jsonl](#) 和 [snapshots/](#)。

未通过或未完成项目

Profile / case	状态	失败原因
deepseek · DeepSeek V4.1 Flash / local-shop-33	completed	shop_oracle_mismatch
glm · GLM 5.3 Flash / local-shop-33	completed	shop_oracle_mismatch
deepseek · DeepSeek V4.1 Flash / local-shop-447	completed	shop_oracle_mismatch
kimi · Kimi K2.6 / local-shop-33	failed	execution_failed, shop_oracle_mismatch
deepseek · DeepSeek V4.1 Flash / local-shop-543	completed	shop_oracle_mismatch
deepseek · DeepSeek V4.1 Flash / local-shop-225	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / local-shop-552	failed	execution_failed
deepseek · DeepSeek V4.1 Flash / local-shop-1342	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / local-shop-231	completed	shop_oracle_mismatch
deepseek · DeepSeek V4.1 Flash / jinan-no-chunithm-record	completed	shop_oracle_mismatch
deepseek · DeepSeek V4.1 Flash / beijing-here-maimai	completed	ValueError, grader_error
kimi · Kimi K2.6 / local-shop-447	completed	shop_oracle_mismatch
kimi · Kimi K2.6 / local-shop-231	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / local-shop-225	failed	execution_failed
mimo · MiMo V2.5 Pro / local-shop-1342	completed	shop_oracle_mismatch
glm · GLM 5.3 Flash / local-shop-447	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / local-shop-4799	failed	execution_failed, shop_oracle_mismatch
mimo · MiMo V2.5 Pro / hangzhou-impressions-exclusion	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / guangzhou-two-malls	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / shanghai-here-maimai	completed	shop_oracle_mismatch
kimi · Kimi K2.6 / local-shop-6013	completed	shop_oracle_mismatch

Profile / case	状态	失败原因
kimi · Kimi K2.6 / tianshui-casual-arcades	failed	execution_failed
mimo · MiMo V2.5 Pro / beijing-here-maimai	completed	shop_oracle_mismatch, forbidden_route
kimi · Kimi K2.6 / guangzhou-two-malls	completed	shop_oracle_mismatch
kimi · Kimi K2.6 / jinan-no-chunithm-record	completed	shop_oracle_mismatch
mimo · MiMo V2.5 Pro / missing-city-clarification	completed	shop_oracle_mismatch
glm · GLM 5.3 Flash / local-shop-4799	completed	shop_oracle_mismatch
kimi · Kimi K2.6 / beijing-here-maimai	completed	shop_oracle_mismatch

length 补测合并说明

本报告以 2026-09-16 全量运行作为基线，对 9 个曾触发 `finish_reason=length` 的模型/用例组合采用 32768 输出上限重新执行，并用补测结果替换对应基线 attempt；每个计划组合仍只计一次。

汇总表、Hard Pass、Judge、成本和图表均按替换后的 152 个有效 attempt 重算。token/费用表是有效 attempt 成本；真实累计账单还包括被替换的旧调用，可在原始基线与补测报告中核对。

Profile	补测数	补测 Hard Pass	补测完整通过
deepseek · DeepSeek V4.1 Flash	1	0/1	0/1
kimi · Kimi K2.6	1	1/1	1/1
glm · GLM 5.3 Flash	7	6/7	6/7


原始补测报告：[20260916T-length-retry-deepseek](#)、[20260916T-length-retry-glm](#)、[20260916T-length-retry-kimi](#)

实际已确认模型费用

下表按账单实际发生汇总，即包括基线里后来被替换的调用以及本次重测；不包含未配置价格的 Judge 调用。上面的“每 task 均价”仍使用修正后的有效 attempt 用量，避免把失败尝试重复算作基准任务成本。

Profile	基线已确认费用 (CNY)	重测已确认费用 (CNY)	实际累计已确认费用 (CNY)
deepseek · DeepSeek V4.1 Flash	10.229574	0.276176	10.505749
glm · GLM 5.3 Flash	4.472415	1.611599	6.084015
kimi · Kimi K2.6	15.467877	0.238301	15.706178
mimo · MiMo V2.5 Pro	7.176162	0.000000	7.176162
合计	37.346028	2.126075	39.472104

模型累计加权完整通过得分与耗时



得分与每 task 均价

